

ĐỒ ÁN TỐT NGHIỆP

**XÂY DỰNG MÔ HÌNH LỘC ĐÁNH GIÁ NGƯỜI DÙNG
NHẪM CẢI THIỆN CHẤT LƯỢNG CỦA
HỆ THỐNG ĐỀ XUẤT**

Ngành: **CÔNG NGHỆ THÔNG TIN**

Chuyên ngành: **CÔNG NGHỆ PHẦN MỀM**

Giảng viên hướng dẫn : PGS.TS. Võ Đình Bảy

Sinh viên thực hiện : Trương Văn Đạt

MSSV: 2180608812 Lớp: 21DTHD6

TP. Hồ Chí Minh, 2025

ĐỒ ÁN TỐT NGHIỆP

**XÂY DỰNG MÔ HÌNH LỘC ĐÁNH GIÁ NGƯỜI DÙNG
NHẪM CẢI THIỆN CHẤT LƯỢNG CỦA
HỆ THỐNG ĐỀ XUẤT**

Ngành: **CÔNG NGHỆ THÔNG TIN**

Chuyên ngành: **CÔNG NGHỆ PHẦN MỀM**

Giảng viên hướng dẫn : PGS.TS. Võ Đình Bảy

Sinh viên thực hiện : Trương Văn Đạt

MSSV: 2180608812 Lớp: 21DTHD6

Giảng viên hướng dẫn	Giảng viên phản biện	Chủ tịch hội đồng

TP. Hồ Chí Minh, 2025

LỜI CAM ĐOAN

Tôi xin cam đoan đồ án tốt nghiệp với đề tài “Xây dựng mô hình lọc đánh giá người dùng nhằm cải thiện chất lượng của hệ thống đề xuất” là kết quả nghiên cứu và làm việc nghiêm túc của cá nhân tôi dưới sự hướng dẫn của giảng viên hướng dẫn.

Toàn bộ nội dung, số liệu, kết quả trình bày trong báo cáo này đều là do tôi trực tiếp thực hiện hoặc trích dẫn từ các nguồn tài liệu đáng tin cậy, có ghi rõ nguồn gốc. Tôi hoàn toàn chịu trách nhiệm trước Hội đồng chấm đồ án và Nhà trường về tính trung thực và nguyên bản của đồ án.

Tôi xin cam kết đồ án này chưa từng được sử dụng để bảo vệ tại bất kỳ nơi nào khác và không vi phạm quy định về đạo văn của Trường Đại học Công nghệ TP. Hồ Chí Minh (HUTECH). Nếu có bất kỳ sai phạm nào liên quan đến bản quyền, tôi xin hoàn toàn chịu trách nhiệm.

MỤC LỤC

CHƯƠNG 1: TỔNG QUAN	1
1.1. Giới thiệu đề tài	1
1.2. Tổng quan nghiên cứu liên quan	1
1.3. Nhiệm vụ của đồ án.....	2
1.4. Cấu trúc của đồ án.....	3
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ	4
2.1. Tổng quan về hệ thống đề xuất.....	4
2.1.1. <i>Hệ thống lọc cộng tác (Collaborative Filtering)</i>	4
2.1.2. <i>Hệ thống lọc theo nội dung (Content-Based Filtering)</i>	4
2.1.3. <i>Hệ thống lai ghép (Hybrid Recommendation Systems)</i>	5
2.2. Kỹ thuật phân rã ma trận (Matrix Factorization).....	5
2.2.1. <i>Khái niệm tổng quan</i>	5
2.2.2. <i>Mô hình toán học</i>	5
2.2.3. <i>Thuật toán huấn luyện</i>	6
2.2.4. <i>Ưu điểm của Matrix Factorization</i>	6
2.2.5. <i>Hạn chế của Matrix Factorization</i>	7
2.2.6. <i>Ứng dụng thực tế</i>	7
2.3. Phân tích cảm xúc trong đánh giá người dùng.....	7
2.3.1. <i>Mục tiêu của phân tích cảm xúc</i>	7
2.3.2. <i>Các mức độ phân tích cảm xúc</i>	7
2.3.3. <i>Các kỹ thuật phân tích cảm xúc</i>	8
2.3.4. <i>Áp dụng trong hệ thống đề xuất</i>	8
2.4. Mô hình SVM trong phân loại văn bản cảm xúc.....	9
2.4.1. <i>Tổng quan về SVM</i>	9
2.4.2. <i>Mô hình toán học</i>	9
2.4.3. <i>SVM trong phân loại văn bản cảm xúc</i>	9
2.4.4. <i>Ứng dụng trong đề tài</i>	10
2.5. Thư viện và công nghệ sử dụng	10
2.5.1. <i>Các thư viện xử lý và phân tích dữ liệu</i>	10
2.5.2. <i>Thư viện học máy và phân tích cảm xúc</i>	11
2.5.3. <i>Các công nghệ triển khai hệ thống đề xuất</i>	11

2.5.4. Quy trình tích hợp hệ thống.....	12
CHƯƠNG 3: PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG.....	13
3.1. Thu thập dữ liệu từ nền tảng thương mại điện tử Tiki.vn.....	13
3.1.1. Mục tiêu thu thập dữ liệu.....	13
3.1.2. Danh mục dữ liệu mục tiêu.....	13
3.1.3. Phương pháp thu thập dữ liệu	13
3.1.4. Tổng quan kết quả thu thập.....	14
3.1.5. Mục tiêu tiền xử lý.....	14
3.1.6. Các bước xử lý văn bản tiếng Việt.....	15
3.1.7. Triển khai luật cụm từ (phrase rules)	16
3.1.8. Loại người dùng có ít đánh giá.....	16
3.2. Thiết kế pipeline xử lý.....	16
3.2.1. Gán nhãn cảm xúc cho dữ liệu	16
3.2.2. Biểu diễn đặc trưng văn bản.....	17
3.2.3. Huấn luyện mô hình phân loại cảm xúc	17
3.2.4. Phát hiện đánh giá không hợp lệ.....	17
3.2.5. Tổng quan pipeline xử lý.....	18
3.3. Mô tả kiến trúc hệ thống: sơ đồ tổng quát các khối chức năng.....	19
3.3.1. Tổng quan hệ thống	19
3.3.2. Luồng dữ liệu và tương tác	20
3.3.3. Khả năng mở rộng và tích hợp.....	21
3.4. Các yếu tố thiết kế quan trọng.....	21
3.4.1. Dữ liệu đầu vào và đầu ra	21
3.4.2. Mô-đun huấn luyện và dự đoán	22
3.4.3. Cơ chế lưu trữ và quản lý kết quả	22
3.4.4. Tính mở rộng và bảo trì	23
CHƯƠNG 4: THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ.....	24
4.1. Thực nghiệm mô hình phân tích cảm xúc.....	24
4.1.1. Tập dữ liệu và tiền xử lý	24
4.1.2. Huấn luyện mô hình và đánh giá.....	26
4.1.3. Phân tích kết quả	27
4.1.4. Minh họa kết quả dự đoán	27

4.1.5. Kết luận phần thực nghiệm cảm xúc.....	28
4.2. Thực nghiệm hệ thống đề xuất.....	28
4.2.1. Thiết lập thực nghiệm.....	28
4.2.2. Các kịch bản thực nghiệm	28
4.2.3. Kết quả thực nghiệm.....	28
4.2.4. Phân tích và nhận xét	29
4.2.5. Kết luận phần thực nghiệm đề xuất	29
4.3. Giao diện website demo	29
4.3.1. Trang chủ và tìm kiếm sản phẩm	30
4.3.2. Trang danh mục sản phẩm	30
4.3.3. Trang chi tiết sản phẩm và đánh giá người dùng	31
4.3.4. Trang gợi ý sản phẩm cá nhân hóa.....	31
4.3.5. Trang quản trị và thống kê hệ thống.....	32
4.3.6. Phân tích đánh giá và lọc nội dung bất thường.....	33
4.3.7. Tổng kết phần giao diện.....	34
CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	35
5.1. Kết luận.....	35
5.2. Hướng phát triển.....	35
TÀI LIỆU THAM KHẢO	37

DANH SÁCH HÌNH VẼ

Hình 2.1: Sơ đồ pipeline tích hợp mô hình lọc đánh giá và hệ thống đề xuất	12
Hình 3.1: Pipeline xử lý văn bản và phát hiện đánh giá không hợp lệ	19
Hình 3.2: Sơ đồ kiến trúc hệ thống lọc đánh giá người dùng và gợi ý sản phẩm	21
Hình 4.1: Biểu đồ Confusion Matrix của mô hình SVM	27
Hình 4.2: Biểu đồ so sánh RMSE giữa các kịch bản.....	29
Hình 4.3: Giao diện trang chủ và tìm kiếm sách	30
Hình 4.4: Giao diện trang danh mục sản phẩm với chức năng tìm kiếm và lọc theo thể loại	31
Hình 4.5: Trang chi tiết sản phẩm và các đánh giá liên quan	31
Hình 4.6: Giao diện gợi ý sách theo cá nhân hóa người dùng	32
Hình 4.7: Giao diện trang quản trị hệ thống với biểu đồ và bảng thống kê	33

DANH SÁCH BẢNG

Bảng 4.1: Phân bố nhãn cảm xúc trong tập dữ liệu huấn luyện	25
Bảng 4.2: Ma trận nhầm lẫn mô hình SVM	26
Bảng 4.3: Một số mẫu đầu vào và nhãn dự đoán cảm xúc	27
Bảng 4.4: So sánh RMSE giữa các kịch bản	29

CHƯƠNG 1: TỔNG QUAN

1.1. Giới thiệu đề tài

Trong kỷ nguyên số hiện nay, các hệ thống đề xuất (recommender systems) đóng vai trò quan trọng trong việc cung cấp các nội dung phù hợp cho người dùng trên các nền tảng thương mại điện tử, dịch vụ truyền thông, mạng xã hội và nhiều lĩnh vực khác. Việc cá nhân hóa trải nghiệm người dùng không chỉ nâng cao hiệu quả kinh doanh mà còn giúp tiết kiệm thời gian tìm kiếm và tăng mức độ hài lòng của khách hàng.

Một trong những yếu tố quan trọng ảnh hưởng đến chất lượng của hệ thống đề xuất chính là dữ liệu đánh giá từ người dùng. Tuy nhiên, trên thực tế, các đánh giá này không phải lúc nào cũng phản ánh đúng cảm nhận thật sự, do tồn tại các đánh giá thiếu trung thực, cảm xúc tiêu cực vô lý hoặc thậm chí là giả mạo. Việc xử lý các đánh giá không hợp lệ này trở thành một vấn đề cấp thiết nhằm cải thiện chất lượng dự đoán của hệ thống đề xuất.

Đề tài “Xây dựng mô hình lọc đánh giá người dùng nhằm cải thiện chất lượng của hệ thống đề xuất” được thực hiện với mục tiêu nhận diện các đánh giá không phản ánh đúng cảm xúc thực sự, từ đó loại bỏ hoặc điều chỉnh để tăng độ chính xác và tin cậy của mô hình đề xuất.

1.2. Tổng quan nghiên cứu liên quan

Các hệ thống đề xuất hiện nay thường dựa trên các phương pháp phổ biến như lọc cộng tác (Collaborative Filtering), lọc theo nội dung (Content-Based Filtering) và mô hình lai (Hybrid Model). Trong đó, phương pháp lọc cộng tác sử dụng đánh giá của người dùng để dự đoán mức độ yêu thích đối với các sản phẩm chưa từng tương tác. Một trong các kỹ thuật tiêu biểu là phân rã ma trận (Matrix Factorization), giúp giảm chiều dữ liệu và tìm ra mối quan hệ tiềm ẩn giữa người dùng và sản phẩm [1].

Nghiên cứu về chất lượng dữ liệu trong hệ thống đề xuất chỉ ra rằng sự hiện diện của đánh giá sai lệch ảnh hưởng lớn đến kết quả dự đoán. Một số công trình đề xuất sử dụng các kỹ thuật xử lý ngôn ngữ tự nhiên (Natural Language Processing – NLP) để phân tích nội dung đánh giá nhằm phát hiện dấu hiệu bất thường [2].

Đặc biệt, việc sử dụng mô hình học máy như SVM (Support Vector Machine) cho bài toán phân loại cảm xúc từ văn bản đánh giá đã được chứng minh mang lại hiệu quả cao [3]. Trong đó, việc chuẩn hóa văn bản, loại bỏ từ dừng, xử lý ngôn ngữ không chính thức là các bước quan trọng trong pipeline xử lý dữ liệu văn bản [4].

Ngoài ra, nhiều nghiên cứu gần đây đã tập trung vào việc kết hợp mô hình lọc đánh giá với hệ thống đề xuất để nâng cao chất lượng đầu ra. Ví dụ, tác giả [5] đề xuất phương pháp phân tích cảm xúc kết hợp lọc đánh giá không phù hợp nhằm cải thiện độ chính xác của mô hình đề xuất.

1.3. Nhiệm vụ của đề án

Lý do chọn đề tài

Trong quá trình phát triển hệ thống đề xuất dựa trên dữ liệu thực tế từ các nền tảng thương mại điện tử như Tiki.vn, tôi nhận thấy có nhiều đánh giá chứa nội dung không phản ánh đúng chất lượng sản phẩm hoặc mang tính thiên lệch. Việc sử dụng nguyên trạng dữ liệu này trong mô hình đề xuất dẫn đến kết quả dự đoán thiếu chính xác. Do đó, đề tài được chọn với mong muốn xây dựng một pipeline xử lý có khả năng lọc ra các đánh giá không hợp lệ nhằm cải thiện hiệu năng của hệ thống.

Mục tiêu nghiên cứu

- Xây dựng pipeline xử lý và phân loại cảm xúc từ các đánh giá văn bản của người dùng.
- Kết hợp mô hình phân tích cảm xúc và điểm đánh giá để phát hiện các đánh giá bất thường.
- Đề xuất hai phương pháp xử lý: (1) loại bỏ đánh giá không hợp lệ; (2) điều chỉnh điểm đánh giá dựa trên cảm xúc.
- Đánh giá tác động của việc lọc đánh giá đến hiệu năng của mô hình đề xuất sử dụng Matrix Factorization.

Ý nghĩa khoa học và thực tiễn

- Về khoa học: Góp phần mở rộng nghiên cứu trong lĩnh vực phân tích cảm xúc và cải thiện chất lượng hệ thống đề xuất.
- Về thực tiễn: Ứng dụng mô hình vào hệ thống thương mại điện tử giúp nâng cao độ tin cậy của đề xuất, tăng trải nghiệm người dùng và hỗ trợ doanh nghiệp ra quyết định chiến lược hiệu quả hơn.

Đối tượng và phạm vi nghiên cứu

- **Đối tượng:** Các đánh giá văn bản từ người dùng trên nền tảng thương mại điện tử.
- **Phạm vi:** Dữ liệu thu thập từ website Tiki.vn, gồm thông tin sản phẩm sách và các đánh giá kèm điểm số. Mô hình đề xuất sử dụng phương pháp Matrix Factorization.

1.4. Cấu trúc của đề án

Đề án được chia thành 5 chương chính như sau:

- **Chương 1: Tổng quan** – Trình bày lý do chọn đề tài, tổng quan các nghiên cứu liên quan, xác định nhiệm vụ, mục tiêu và cấu trúc đề án.
- **Chương 2: Cơ sở lý thuyết và công nghệ** – Trình bày các kiến thức nền tảng như hệ thống đề xuất, phân tích cảm xúc, mô hình SVM, Matrix Factorization và các thư viện liên quan.
- **Chương 3: Phân tích và thiết kế hệ thống** – Mô tả quá trình thu thập dữ liệu, xử lý ngôn ngữ tự nhiên, xây dựng pipeline phát hiện đánh giá không hợp lệ và tích hợp vào hệ thống đề xuất.
- **Chương 4: Thực nghiệm và đánh giá kết quả** – Trình bày các kịch bản đánh giá mô hình: giữ nguyên dữ liệu gốc, loại bỏ và điều chỉnh đánh giá, từ đó phân tích tác động đến hệ thống đề xuất.
- **Chương 5: Kết luận và hướng phát triển** – Tổng kết những đóng góp, nêu ra giới hạn và đề xuất hướng phát triển trong tương lai như tích hợp mô hình lai, sử dụng dữ liệu lớn hoặc deep learning.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ

2.1. Tổng quan về hệ thống đề xuất

Hệ thống đề xuất (Recommender Systems) là một trong những ứng dụng phổ biến của trí tuệ nhân tạo nhằm cá nhân hóa trải nghiệm người dùng. Chúng được sử dụng rộng rãi trong các nền tảng thương mại điện tử, dịch vụ truyền phát nội dung (như Netflix, Spotify), mạng xã hội và nhiều lĩnh vực khác nhằm cung cấp các đề xuất phù hợp với sở thích và hành vi của từng người dùng.

Ba nhóm chính trong các hệ thống đề xuất bao gồm: **lọc cộng tác (Collaborative Filtering)**, **lọc theo nội dung (Content-Based Filtering)** và **lai ghép (Hybrid)**.

2.1.1. Hệ thống lọc cộng tác (Collaborative Filtering)

Lọc cộng tác là phương pháp đề xuất dựa trên hành vi hoặc đánh giá của người dùng khác có sở thích tương tự. Ý tưởng cốt lõi là: nếu người A và người B cùng thích các sản phẩm giống nhau, thì những sản phẩm mà A thích nhưng B chưa xem có khả năng cao sẽ phù hợp với B.

Có hai dạng chính của Collaborative Filtering:

- **Dựa trên người dùng (User-Based CF)**: Xác định các người dùng có thị hiếu tương đồng, sau đó sử dụng đánh giá của họ để đưa ra đề xuất.

- **Dựa trên sản phẩm (Item-Based CF)**: Xác định các sản phẩm tương tự dựa trên đánh giá của người dùng và đề xuất sản phẩm tương tự với những gì người dùng đã thích.

Một số kỹ thuật điển hình sử dụng trong CF bao gồm:

- Tính toán độ tương đồng (similarity) giữa người dùng hoặc sản phẩm bằng các độ đo như Cosine, Pearson, Jaccard.

- Xây dựng ma trận người dùng – sản phẩm (user-item matrix) và áp dụng các kỹ thuật giảm chiều như Matrix Factorization.

2.1.2. Hệ thống lọc theo nội dung (Content-Based Filtering)

Content-Based Filtering đề xuất sản phẩm dựa trên đặc điểm của sản phẩm và hồ sơ người dùng. Hệ thống học từ các thuộc tính của các sản phẩm mà người dùng đã yêu thích trong quá khứ và từ đó dự đoán sản phẩm mới có thể phù hợp.

Các đặc điểm kỹ thuật:

- Mỗi sản phẩm được biểu diễn bằng một vector đặc trưng (feature vector) như thể loại, mô tả, thương hiệu, v.v.

- Hồ sơ người dùng (user profile) được xây dựng từ các sản phẩm mà họ đánh giá cao.
- Đề xuất được đưa ra bằng cách tính độ tương đồng giữa sản phẩm mới và hồ sơ người dùng.

Ưu điểm của phương pháp này là khả năng đề xuất cho người dùng mới (cold-start user) nếu có thông tin về sản phẩm họ đã tương tác. Tuy nhiên, phương pháp này thường bị giới hạn bởi không gian đặc trưng và dễ rơi vào tình trạng "bong bóng lọc" (filter bubble) — người dùng chỉ nhận được những đề xuất quá giống với lịch sử tương tác.

2.1.3. Hệ thống lai ghép (Hybrid Recommendation Systems)

Hệ thống lai ghép kết hợp cả Collaborative Filtering và Content-Based Filtering để tận dụng ưu điểm và khắc phục hạn chế của từng phương pháp.

Có nhiều chiến lược lai ghép:

- **Kết hợp tuần tự (Sequential Hybrid):** Áp dụng một phương pháp đầu tiên (ví dụ Content-Based) để lọc trước, sau đó áp dụng CF để xếp hạng.
- **Kết hợp song song (Parallel Hybrid):** Áp dụng cả hai phương pháp đồng thời và trộn kết quả theo trọng số.
- **Kết hợp tích hợp (Feature Augmentation):** Kết hợp đặc trưng từ một phương pháp làm đầu vào cho phương pháp còn lại.

Hybrid Recommendation Systems có khả năng mở rộng tốt hơn, nâng cao độ chính xác và giảm thiểu hiệu ứng cold-start. Đây là xu hướng được sử dụng phổ biến trong các hệ thống đề xuất hiện đại.

2.2. Kỹ thuật phân rã ma trận (Matrix Factorization)

2.2.1. Khái niệm tổng quan

Matrix Factorization (MF) là một trong những kỹ thuật quan trọng và phổ biến nhất trong hệ thống đề xuất, đặc biệt trong các phương pháp Collaborative Filtering. Ý tưởng chính là phân rã ma trận tương tác người dùng – sản phẩm (user-item matrix) thành hai ma trận mật độ thấp đại diện cho đặc trưng tiềm ẩn của người dùng và sản phẩm.

MF đã được sử dụng thành công trong nhiều hệ thống thực tế, đáng chú ý nhất là chiến thắng của nhóm BellKor tại cuộc thi Netflix Prize 2009.

2.2.2. Mô hình toán học

Giả sử ta có một ma trận đánh giá $R \in \mathbb{R}^{m \times n}$, trong đó R_{ui} biểu thị điểm số mà người dùng u đánh giá sản phẩm i . Trong thực tế, ma trận này rất thưa (sparse), tức là có nhiều giá trị bị thiếu (unknown ratings).

Mục tiêu của MF là tìm hai ma trận ẩn:

- $P \in \mathbb{R}^{m \times k}$: ma trận đặc trưng của người dùng (user-feature matrix)
- $Q \in \mathbb{R}^{n \times k}$: ma trận đặc trưng của sản phẩm (item-feature matrix)

sao cho:

$$R_{ui} \approx \hat{R}_{ui} = P_u \cdot Q_i^T$$

trong đó:

- P_u là vector đặc trưng của người dùng u
- Q_i là vector đặc trưng của sản phẩm i
- k là số lượng đặc trưng tiềm ẩn (latent factors)

Để tìm các ma trận P và Q , ta giải bài toán tối ưu hàm mất mát:

$$\min_{P, Q} \sum_{(u, i) \in \mathcal{K}} (R_{ui} - P_u \cdot Q_i^T)^2 + \lambda (\|P_u\|^2 + \|Q_i\|^2)$$

trong đó:

- \mathcal{K} là tập hợp các cặp người dùng – sản phẩm có đánh giá thực tế.
- λ là hệ số điều chuẩn (regularization parameter) nhằm tránh hiện tượng

overfitting.

2.2.3. Thuật toán huấn luyện

Một trong các phương pháp phổ biến để tối ưu bài toán trên là **Stochastic Gradient Descent (SGD)**. Quy trình cập nhật tham số như sau:

$$\text{Lỗi dự đoán: } e_{ui} = R_{ui} - \hat{R}_{ui} \tag{2.3}$$

$$P_u \leftarrow P_u + \eta(e_{ui}Q_i - \lambda P_u) \tag{2.4}$$

$$Q_i \leftarrow Q_i + \eta(e_{ui}P_u - \lambda Q_i) \tag{2.5}$$

Trong đó η là tốc độ học (learning rate).

2.2.4. Ưu điểm của Matrix Factorization

- **Tính khái quát cao:** MF có khả năng khai thác thông tin tiềm ẩn trong mối quan hệ người dùng – sản phẩm, không chỉ đơn thuần dựa trên điểm số.

- **Hiệu suất tốt với dữ liệu thưa:** Dễ dàng mở rộng cho các tập dữ liệu lớn và thưa như MovieLens, Netflix.

- **Có thể kết hợp thêm thông tin phụ:** MF có thể được mở rộng thành các mô

hình phức tạp hơn như SVD++, Factorization Machines để tích hợp thông tin hồ sơ người dùng, ngữ cảnh, thời gian.

2.2.5. Hạn chế của Matrix Factorization

- **Không xử lý tốt với người dùng hoặc sản phẩm mới (Cold-start problem):** Cần có đủ đánh giá để học đặc trưng ẩn.
- **Không tận dụng đặc trưng nội dung:** Không dùng thông tin mô tả sản phẩm hoặc hồ sơ người dùng nếu không mở rộng mô hình.
- **Yêu cầu xử lý dữ liệu đầu vào kỹ lưỡng:** Cần chuẩn hóa ma trận đầu vào, xử lý mất mát và nhiễu (ví dụ: đánh giá không hợp lệ).

2.2.6. Ứng dụng thực tế

Matrix Factorization thường được sử dụng như nền tảng cho hệ thống gợi ý sản phẩm trong các nền tảng thương mại điện tử, dịch vụ streaming, mạng xã hội. Trong khuôn khổ đề tài này, MF được áp dụng để xây dựng mô hình đề xuất dựa trên dữ liệu đánh giá đã được xử lý cảm xúc, nhằm cải thiện độ tin cậy của mô hình đề xuất tổng thể.

2.3. Phân tích cảm xúc trong đánh giá người dùng

2.3.1. Mục tiêu của phân tích cảm xúc

Phân tích cảm xúc (Sentiment Analysis), hay còn gọi là phân loại quan điểm (opinion mining), là một kỹ thuật trong xử lý ngôn ngữ tự nhiên (NLP) nhằm xác định thái độ, quan điểm hoặc cảm xúc của người dùng đối với một chủ thể nào đó (sản phẩm, dịch vụ, nội dung...).

Trong ngữ cảnh hệ thống đề xuất, phân tích cảm xúc giúp đánh giá mức độ tích cực hay tiêu cực của các bình luận người dùng. Điều này đặc biệt hữu ích khi điểm số đánh giá (rating) không phản ánh đúng nội dung bình luận — một tình huống phổ biến dẫn đến đánh giá sai lệch, ảnh hưởng đến hiệu quả gợi ý.

2.3.2. Các mức độ phân tích cảm xúc

Phân tích cảm xúc có thể được thực hiện ở nhiều mức độ:

- **Mức văn bản (Document-level):** Xác định cảm xúc tổng thể của toàn bộ bình luận.
- **Mức câu (Sentence-level):** Phân tích cảm xúc trong từng câu đơn lẻ.
- **Mức khía cạnh (Aspect-level):** Xác định cảm xúc liên quan đến các thành phần cụ thể của sản phẩm (ví dụ: pin, màn hình, giá cả...).

Trong đề tài này, tập trung chính vào **phân loại cảm xúc mức văn bản**, phù hợp

với độ dài và cấu trúc ngữ nghĩa của các bình luận đánh giá sản phẩm.

2.3.3. Các kỹ thuật phân tích cảm xúc

Có nhiều phương pháp phân tích cảm xúc, được chia thành ba nhóm chính:

Phương pháp dựa trên từ điển (Lexicon-based)

Sử dụng các từ điển cảm xúc chứa danh sách các từ tích cực và tiêu cực. Tổng điểm cảm xúc được tính dựa trên số lượng và trọng số của các từ xuất hiện trong văn bản.

Ưu điểm: Đơn giản, dễ triển khai.

Hạn chế: Phụ thuộc mạnh vào chất lượng từ điển, kém hiệu quả với từ lóng, teencode, ngôn ngữ địa phương.

Phương pháp học máy truyền thống (Machine Learning)

Xem phân tích cảm xúc là một bài toán phân loại văn bản. Các bước bao gồm:

1. Tiền xử lý dữ liệu: loại bỏ stopwords, emoji, từ đặc biệt, chuẩn hóa teencode.
2. Trích xuất đặc trưng: TF-IDF, Bag-of-Words, n-gram.
3. Áp dụng mô hình phân loại: Naïve Bayes, Logistic Regression, SVM...

Ưu điểm: Dễ huấn luyện, kiểm soát được mô hình.

Hạn chế: Hiệu quả phụ thuộc vào chất lượng đặc trưng.

Phương pháp học sâu (Deep Learning)

Sử dụng các mô hình như RNN, LSTM, hoặc Transformer (BERT, PhoBERT) để học biểu diễn ngữ nghĩa ngữ cảnh. Đây là hướng hiện đại và có độ chính xác cao.

Ưu điểm: Tự động học đặc trưng ngữ nghĩa phức tạp.

Hạn chế: Yêu cầu tài nguyên tính toán và dữ liệu lớn.

2.3.4. Áp dụng trong hệ thống đề xuất

Trong đề tài này, phân tích cảm xúc được sử dụng nhằm:

- Phát hiện các đánh giá không nhất quán giữa văn bản và điểm số (ví dụ: bình luận tiêu cực nhưng cho 5 sao).
- Lọc bỏ hoặc điều chỉnh các đánh giá sai lệch nhằm cải thiện độ tin cậy của dữ liệu đầu vào cho mô hình đề xuất.
- Làm sạch dữ liệu (data cleaning) trước khi huấn luyện mô hình MF.

Quy trình áp dụng gồm các bước:

1. Thu thập dữ liệu đánh giá và bình luận từ Tiki.vn.
2. Áp dụng mô hình phân loại cảm xúc đã huấn luyện (SVM) để xác định nhãn cảm xúc.

3. Đối chiếu với điểm số gốc để phát hiện các đánh giá bất thường.
4. Tùy chọn: loại bỏ hoặc điều chỉnh điểm số trong ma trận đánh giá.

Việc tích hợp phân tích cảm xúc vào pipeline hệ thống gợi ý giúp gia tăng tính chính xác và phản ánh đúng trải nghiệm thực tế của người dùng, thay vì chỉ dựa vào điểm số.

2.4. Mô hình SVM trong phân loại văn bản cảm xúc

2.4.1. Tổng quan về SVM

Support Vector Machine (SVM) là một thuật toán học có giám sát mạnh mẽ, thường được sử dụng cho các bài toán phân loại nhị phân và hồi quy. SVM được phát triển dựa trên nguyên lý tìm ra siêu phẳng (hyperplane) tối ưu phân tách các điểm dữ liệu thuộc các lớp khác nhau sao cho khoảng cách giữa siêu phẳng và các điểm dữ liệu gần nhất là lớn nhất (maximum margin).

Trong phân tích cảm xúc, SVM được ứng dụng để phân loại văn bản (bình luận, đánh giá) thành các nhóm như *tích cực*, *tiêu cực*, hoặc *trung lập*.

2.4.2. Mô hình toán học

Giả sử có tập dữ liệu huấn luyện:

$$\{(\mathbf{x}_i, y_i)\}_{i=1}^N, \quad \mathbf{x}_i \in \mathbb{R}^d, \quad y_i \in \{-1, +1\}$$

với \mathbf{x}_i là vector đặc trưng của văn bản (ví dụ: TF-IDF), và y_i là nhãn cảm xúc.

SVM tìm một siêu phẳng phân tách có dạng:

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b = 0$$

Mục tiêu là tối ưu hóa hàm mục tiêu:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{subject to} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad \forall i$$

Nếu dữ liệu không tuyến tính, ta sử dụng hàm nhân (kernel function) $\kappa(\mathbf{x}_i, \mathbf{x}_j)$ để ánh xạ lên không gian mới:

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$$

Một số hàm kernel phổ biến:

- **Linear kernel:** $\kappa(\mathbf{x}, \mathbf{x}') = \mathbf{x}^T \mathbf{x}'$
- **Polynomial kernel:** $\kappa(\mathbf{x}, \mathbf{x}') = (\mathbf{x}^T \mathbf{x}' + 1)^d$
- **RBF kernel:** $\kappa(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2)$

2.4.3. SVM trong phân loại văn bản cảm xúc

Trong bài toán phân loại cảm xúc, mỗi văn bản (bình luận) được biểu diễn thành

một vector đặc trưng thông qua kỹ thuật như TF-IDF, n-gram hoặc Word Embedding. Sau đó, các vector này được đưa vào mô hình SVM để huấn luyện.

Các bước thực hiện

1. **Tiền xử lý văn bản:** chuẩn hóa văn bản, xóa emoji, từ dừng, chuyển về chữ thường, tách từ.
2. **Trích xuất đặc trưng:** TF-IDF với uni-gram, bi-gram.
3. **Huấn luyện mô hình SVM:** sử dụng tập huấn luyện có nhãn cảm xúc.
4. **Dự đoán cảm xúc:** áp dụng mô hình đã huấn luyện để gán nhãn cho các bình luận mới.

Ưu điểm của SVM

- Hoạt động hiệu quả với dữ liệu có chiều cao như văn bản.
- Phù hợp với bài toán phân loại nhị phân hoặc đa lớp.
- Tối ưu tốt khi có khoảng cách rõ ràng giữa các lớp.

Hạn chế

- Nhạy cảm với dữ liệu nhiễu và mất cân bằng lớp.
- Chi phí tính toán cao nếu kích thước tập huấn luyện lớn.
- Cần lựa chọn tham số kernel, C , và γ phù hợp.

2.4.4. Ứng dụng trong đề tài

Trong đề tài, mô hình SVM được sử dụng như bộ phân loại cảm xúc chính, áp dụng sau bước tiền xử lý tiếng Việt. SVM giúp xác định các bình luận tích cực hoặc tiêu cực một cách chính xác, từ đó hỗ trợ quá trình lọc và điều chỉnh đánh giá người dùng nhằm nâng cao chất lượng dữ liệu đầu vào cho hệ thống đề xuất.

2.5. Thư viện và công nghệ sử dụng

Trong quá trình xây dựng mô hình lọc đánh giá người dùng nhằm cải thiện chất lượng hệ thống đề xuất, đề tài sử dụng nhiều thư viện và công nghệ từ học máy, xử lý ngôn ngữ tự nhiên cho đến các công cụ triển khai ứng dụng web. Mục tiêu là đảm bảo hiệu quả trong xử lý dữ liệu, huấn luyện mô hình và tích hợp hệ thống khuyến nghị vào ứng dụng thực tế.

2.5.1. Các thư viện xử lý và phân tích dữ liệu

- **Pandas:** thư viện mạnh mẽ dùng để thao tác dữ liệu dạng bảng (DataFrame). Được sử dụng trong các bước xử lý dữ liệu đầu vào, phân tích thống kê và chuẩn bị tập huấn luyện.

- **NumPy:** hỗ trợ tính toán ma trận, vector và các thao tác số học hiệu năng cao.
- **Matplotlib, Seaborn:** phục vụ việc trực quan hóa dữ liệu và kết quả mô hình (biểu đồ tần suất đánh giá, độ chính xác, phân phối điểm số...).

2.5.2. Thư viện học máy và phân tích cảm xúc

- **scikit-learn:** thư viện học máy mã nguồn mở, được sử dụng cho:
 - Tiền xử lý đặc trưng văn bản (TF-IDF, chuẩn hóa).
 - Huấn luyện mô hình SVM phân loại cảm xúc.
 - Đánh giá mô hình (cross-validation, accuracy, confusion matrix...).
- **Surprise:** thư viện chuyên biệt cho hệ thống đề xuất, đặc biệt là các mô hình dựa trên ma trận. Được sử dụng để xây dựng mô hình *Matrix Factorization* với thuật toán SVD hoặc SVD++.

- **Underthesea, PyVi, VnCoreNLP:** các công cụ xử lý ngôn ngữ tự nhiên tiếng Việt, phục vụ:

- Tách từ tiếng Việt (word segmentation).
- Chuẩn hóa teencode và ngôn ngữ không chuẩn.
- Gán nhãn từ loại, phân tích câu.
- **emoji, unicode, re:** thư viện hỗ trợ làm sạch dữ liệu văn bản như loại bỏ biểu tượng cảm xúc, ký tự đặc biệt, chuyển đổi dấu.

2.5.3. Các công nghệ triển khai hệ thống đề xuất

Sau khi xây dựng mô hình lọc đánh giá và mô hình đề xuất, hệ thống được triển khai thành một ứng dụng web cho phép người dùng tương tác. Các công nghệ sử dụng gồm:

Backend: NodeJS

- Được sử dụng để xây dựng API trung gian giữa frontend và cơ sở dữ liệu.
- Triển khai các hàm gọi mô hình dự đoán từ server.
- Xử lý logic xác thực người dùng và truy vấn sản phẩm.

Frontend: NextJS

- Framework ReactJS được tối ưu hóa cho hiệu suất và SEO.
- Giao diện hiển thị danh sách sản phẩm được đề xuất, điểm đánh giá, bình luận.
- Giao tiếp với API backend thông qua RESTful hoặc GraphQL.

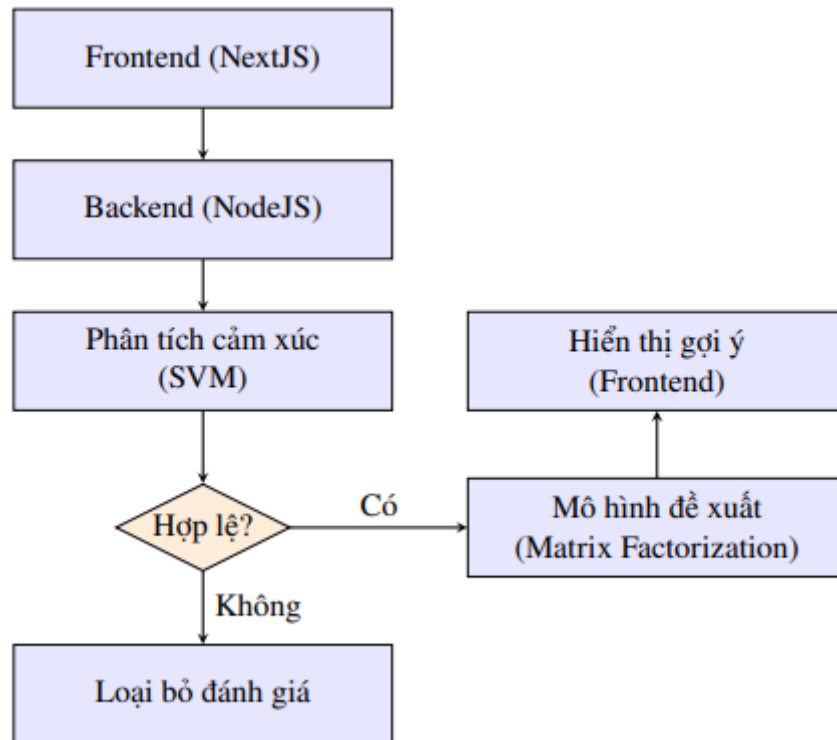
Cơ sở dữ liệu: MongoDB

- Cơ sở dữ liệu NoSQL dạng document, phù hợp với dữ liệu phi cấu trúc như đánh

giá, hồ sơ người dùng.

- Lưu trữ các sản phẩm, người dùng, đánh giá đã được gán nhãn cảm xúc và kết quả đề xuất.
- Tích hợp tốt với NodeJS qua thư viện Mongoose.

2.5.4. Quy trình tích hợp hệ thống



Hình 2.1: Sơ đồ pipeline tích hợp mô hình lọc đánh giá và hệ thống đề xuất

1. Người dùng truy cập hệ thống qua giao diện NextJS.
2. Dữ liệu đánh giá được gửi về backend NodeJS.
3. Backend xử lý dữ liệu, gọi mô hình SVM để xác định cảm xúc, kiểm tra độ tin cậy.
4. Nếu đánh giá hợp lệ, điểm được đưa vào hệ thống đề xuất MF.
5. Kết quả gợi ý sản phẩm trả về frontend và hiển thị.

Hệ thống đảm bảo tính mở rộng và có thể nâng cấp để tích hợp các mô hình hiện đại hơn như Deep Learning hoặc mô hình học liên tục (online learning).

CHƯƠNG 3: PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

3.1. Thu thập dữ liệu từ nền tảng thương mại điện tử Tiki.vn

3.1.1. Mục tiêu thu thập dữ liệu

Trong bối cảnh xây dựng hệ thống lọc đánh giá người dùng nhằm cải thiện chất lượng của hệ thống đề xuất, việc thu thập một tập dữ liệu thực tế, đa dạng và phản ánh đúng hành vi đánh giá của người dùng là điều kiện tiên quyết. Nền tảng thương mại điện tử Tiki.vn được lựa chọn bởi vì đây là một trong những website thương mại điện tử hàng đầu tại Việt Nam, sở hữu số lượng lớn sản phẩm và bình luận đánh giá từ phía người dùng, đặc biệt trong lĩnh vực sách – nơi cảm xúc đóng vai trò quan trọng trong hành vi tiêu dùng.

3.1.2. Danh mục dữ liệu mục tiêu

Tập dữ liệu cần thu thập bao gồm hai thành phần chính:

- **Thông tin sản phẩm:** bao gồm tiêu đề, mô tả, tác giả (đối với sách), danh mục, giá bán, và điểm đánh giá trung bình.
- **Đánh giá người dùng (user reviews):** bao gồm nội dung bình luận, điểm số (rating), thời gian đánh giá, và các phản hồi (nếu có).

Tập trung vào nhóm sản phẩm sách, sáu danh mục được chọn gồm: sách văn học, sách kinh tế, sách kỹ năng sống, nuôi dạy con, sách kiến thức tổng hợp và sách lịch sử địa lý.

3.1.3. Phương pháp thu thập dữ liệu

Việc thu thập dữ liệu được thực hiện thông qua cách tiếp cận **web crawling** sử dụng các API công khai của Tiki. Để đảm bảo khả năng tái lập và tính hệ thống, tôi đã xây dựng một tập hợp script Python tự động hoá toàn bộ quá trình thu thập sản phẩm và đánh giá tương ứng. Quá trình được chia thành các bước như sau:

Bước 1: Lấy danh sách sản phẩm theo danh mục

Dữ liệu được truy xuất từ endpoint:

`https://tiki.vn/api/personalish/v1/blocks/listings`

API này trả về danh sách các sản phẩm thuộc danh mục được chỉ định thông qua `category_id`. Với mỗi danh mục, hệ thống sẽ lặp qua nhiều trang kết quả (tối đa 3 trang đầu tiên để đảm bảo tính thực thi và giảm tải).

Bước 2: Truy xuất chi tiết sản phẩm

Với mỗi sản phẩm thu được, hệ thống tiếp tục truy xuất thông tin chi tiết qua API:

`https://tiki.vn/api/v2/products/{product_id}`

Dữ liệu chi tiết được lưu trữ dưới định dạng JSON với cấu trúc cây, bao gồm các trường như tiêu đề, mô tả, giá bán, số lượng đánh giá, số điểm trung bình, thuộc tính chi tiết.

Bước 3: Truy xuất đánh giá người dùng

Sau khi thu được mã sản phẩm (product_id), đánh giá của người dùng được truy xuất qua endpoint:

`https://tiki.vn/api/v2/reviews?product_id={id}&page={n}`

Quá trình này được thực hiện theo trang, cho đến khi không còn trang dữ liệu mới hoặc đạt đến trang cuối cùng được chỉ định trong phản hồi API. Các đánh giá được trích xuất bao gồm nội dung văn bản, điểm số, thời gian đánh giá, và các tương tác đi kèm (nếu có).

Bước 4: Lưu trữ và tổ chức dữ liệu

Toàn bộ dữ liệu được lưu dưới cấu trúc cây thư mục rõ ràng:

- data/raw/products/{category}: chứa các tệp JSON sản phẩm theo danh mục.
- data/raw/reviews/{category}: chứa các tệp JSON đánh giá theo danh mục sản phẩm.

Mỗi sản phẩm và tệp đánh giá tương ứng được lưu tách biệt, đảm bảo dễ dàng thao tác và tiền xử lý về sau.

3.1.4. Tổng quan kết quả thu thập

Sau khi hoàn tất tiến trình thu thập, hệ thống đã xây dựng được một tập dữ liệu thực tế có quy mô lớn bao gồm:

- **Tổng số đánh giá:** 296.836 đánh giá người dùng.
- **Số lượng người dùng duy nhất:** 181.741 người dùng.
- **Số lượng sản phẩm sách duy nhất:** 881 sản phẩm.

Tập dữ liệu có độ bao phủ cao, phản ánh hành vi và quan điểm tiêu dùng từ nhiều phân khúc người dùng khác nhau. Đây là cơ sở vững chắc để triển khai các bước phân tích cảm xúc, phát hiện đánh giá không hợp lệ và đánh giá hiệu quả mô hình đề xuất trong các phần tiếp theo của đề án. Quy trình tiền xử lý dữ liệu

3.1.5. Mục tiêu tiền xử lý

Dữ liệu văn bản thu thập từ các đánh giá người dùng trên nền tảng Tiki.vn thường mang tính tự do, không chuẩn hóa, chứa nhiều ký hiệu, từ viết tắt (teencode), từ ngữ địa

phương hoặc cảm tính. Để đảm bảo chất lượng đầu vào cho mô hình học máy, đặc biệt là mô hình phân loại cảm xúc và phát hiện đánh giá không hợp lệ, việc xây dựng một pipeline tiền xử lý ngôn ngữ tự nhiên tiếng Việt chuyên biệt là yêu cầu thiết yếu.

3.1.6. Các bước xử lý văn bản tiếng Việt

Pipeline tiền xử lý văn bản được thiết kế theo các bước sau:

- **Làm sạch dữ liệu:** Loại bỏ các ký tự không cần thiết như emoji, biểu tượng cảm xúc, liên kết URL, đoạn văn bị lỗi (ví dụ: `_x000D_`), và chuẩn hóa định dạng văn bản về chữ thường.

- **Chuẩn hóa từ viết tắt và teencode:** Áp dụng từ điển ánh xạ gồm các từ teencode phổ biến sang tiếng Việt chuẩn. Ví dụ: “hok” → “không”, “tks” → “cảm ơn”.

- **Chuẩn hóa cụm từ phổ biến (phrase rules):** Các cụm từ thường xuất hiện trong đánh giá được nối lại thành đơn vị từ ghép bằng dấu gạch dưới. Ví dụ: “giao hàng” → “giao_hàng”, “chất lượng” → “chất_lượng”. Luật này đặc biệt quan trọng nhằm bảo toàn ngữ nghĩa trong phân tích cảm xúc và cải thiện độ chính xác mô hình. Bộ luật được trích xuất từ dữ liệu thực tế và bao gồm hàng trăm cụm từ quan trọng như: “bao bọc”, “bìa sách”, “dịch vụ”, “giá cả”, “mùa dịch”, “giao nhầm”, “bản dịch”, “móp méo”, “sách đẹp”, ...

- **Chuẩn hóa ký tự lặp:** Loại bỏ hoặc giảm số lượng ký tự lặp không cần thiết nhằm xử lý hiện tượng nhấn mạnh cảm xúc (ví dụ: “hayyyy” → “hay”).

- **Tách từ:** Sử dụng công cụ tách từ tiếng Việt ViTokenizer để phân đoạn văn bản thành các từ đơn vị, hỗ trợ bước biểu diễn đặc trưng.

- **Xử lý phủ định và cụm ngữ cảnh tiêu cực:** Nhằm bảo toàn ngữ nghĩa cảm xúc, hệ thống thực hiện nối cụm từ có chứa tiền tố phủ định như “không”, “chưa”, “đừng” với động từ đi sau, ví dụ: “không tốt” → “không_tốt”, “không có bọc” → “không_có_bọc”. Đồng thời xử lý các chỉ dấu tiêu cực như “bị”, “thiếu”, “nên”, “được” để xác định rõ thái độ đánh giá.

- **Xoá từ dừng (stopwords):** Áp dụng danh sách từ dừng tiếng Việt được biên soạn thủ công, bao gồm các từ không mang ý nghĩa phân biệt trong cảm xúc như “là”, “một”, “có”, “những”, “và”, ...nhằm giảm nhiễu.

- **Xử lý cụ thể cho một số cụm thường gặp:** Một số cụm từ có nhiều biến thể như “giao hàng”, “bao bọc”, “bọc sách”, “giao nhanh” được xử lý riêng để tăng tính nhất quán trong biểu diễn văn bản.

3.1.7. Triển khai luật cụm từ (phrase rules)

Bộ luật cụm từ được xây dựng từ tập dữ liệu thực tế bằng cách trích xuất các n-gram có tần suất cao và ngữ nghĩa rõ ràng. Các cụm từ này có tác dụng quan trọng trong việc giữ nguyên khối ngữ nghĩa, ví dụ:

- **Giao nhận và đóng gói:** *giao hàng, đóng gói, gói hàng, vận chuyển, giao nhầm, giao chậm.*

- **Chất lượng sản phẩm:** *chất lượng, sách mới, sách rách, sách đẹp, sách bản.*

- **Cảm nhận của người dùng:** *hài lòng, thất vọng, xuất sắc, phí tiền, tuyệt vời, đáng kể.*

- **Thuật ngữ chuyên ngành:** *sách kỹ năng, sách giáo khoa, truyện tranh, bản dịch, kiến thức.*

- **Cụm từ nhấn mạnh cảm xúc:** *100 điểm, siêu nhanh, tuyệt vời ông mặt trời, toẹt zời, must have.*

Việc chuẩn hóa các cụm từ này không chỉ cải thiện tính đồng nhất trong biểu diễn dữ liệu mà còn hỗ trợ mô hình phát hiện các đánh giá giả mạo vốn thường lặp lại cụm từ mẫu, thiếu sự tự nhiên.

3.1.8. Lọc người dùng có ít đánh giá

Một bước quan trọng trong quá trình tiền xử lý là loại bỏ các người dùng có số lượng đánh giá quá ít (ít hơn 3 đánh giá), nhằm đảm bảo rằng các đặc trưng liên quan đến hành vi người dùng có đủ thông tin để học. Việc lọc này nhằm:

- Giảm thiểu độ thừa của ma trận người dùng–sản phẩm.
- Loại bỏ các tài khoản khả nghi hoặc đánh giá thử nghiệm (noise).
- Cải thiện hiệu quả và độ tin cậy của các thuật toán học máy.

Tổng thể, sau khi áp dụng các bước tiền xử lý, dữ liệu văn bản được đưa về định dạng sạch, thống nhất, dễ học và sẵn sàng cho bước tiếp theo: gán nhãn cảm xúc và phân loại.

3.2. Thiết kế pipeline xử lý

Sau khi hoàn thiện bước thu thập và tiền xử lý dữ liệu, hệ thống tiến hành xây dựng pipeline xử lý nhằm phục vụ cho ba nhiệm vụ chính: (1) gán nhãn cảm xúc cho đánh giá, (2) huấn luyện mô hình phân loại văn bản dựa trên cảm xúc, và (3) phát hiện các đánh giá không hợp lệ dựa trên sự sai lệch giữa nội dung cảm xúc và điểm số.

3.2.1. Gán nhãn cảm xúc cho dữ liệu

Để xây dựng tập huấn luyện cho bài toán phân loại cảm xúc, hệ thống dựa vào điểm đánh giá (rating) do người dùng cung cấp. Mỗi đánh giá được gán một nhãn cảm xúc như sau:

- **Tích cực (Positive):** nếu rating ≥ 4 .
- **Tiêu cực (Negative):** nếu rating ≤ 2 .
- **Trung lập (Neutral):** nếu rating = 3 (các đánh giá này được loại bỏ trong giai đoạn huấn luyện để tăng tính rõ ràng cho mô hình phân loại nhị phân).

Tập dữ liệu huấn luyện cuối cùng bao gồm các cặp (văn bản đánh giá, nhãn cảm xúc) với hai lớp: tích cực và tiêu cực.

3.2.2. Biểu diễn đặc trưng văn bản

Dữ liệu sau khi tiền xử lý được biểu diễn thành dạng số sử dụng mô hình **TF-IDF (Term Frequency – Inverse Document Frequency)**. Kỹ thuật này giúp đánh giá mức độ quan trọng của một từ trong một văn bản, tương quan với toàn bộ tập dữ liệu. Một số cấu hình được sử dụng cho bộ biểu diễn TF-IDF:

- **max_features = 3000:** giới hạn số lượng đặc trưng tối đa.
- **min_df = 5:** loại bỏ các từ xuất hiện ít hơn 5 lần trong toàn bộ tập.
- **max_df = 0.8:** loại bỏ các từ xuất hiện trong hơn 80% tài liệu (có thể là stopword).
- **sublinear_tf = True:** áp dụng phép biến đổi logarit để làm mượt tần suất.

Kết quả là mỗi văn bản được ánh xạ thành một vector không gian đặc trưng thưa (sparse vector), phản ánh mức độ nổi bật của từng cụm từ trong ngữ cảnh cảm xúc.

3.2.3. Huấn luyện mô hình phân loại cảm xúc

Với tập dữ liệu đã được vector hóa, hệ thống sử dụng mô hình **SVM tuyến tính (Linear Support Vector Machine)** để huấn luyện bộ phân loại cảm xúc. SVM được lựa chọn nhờ khả năng phân tách tốt trong không gian chiều cao, đặc biệt hiệu quả với dữ liệu văn bản thưa và tuyến tính.

Trong quá trình huấn luyện, mô hình học được siêu mặt phân tách tối ưu giữa hai lớp cảm xúc (tích cực và tiêu cực), dựa trên các đặc trưng n-gram từ TF-IDF. Mô hình sau huấn luyện đạt độ chính xác cao trên tập kiểm thử (chi tiết kết quả sẽ được trình bày tại Chương 4).

3.2.4. Phát hiện đánh giá không hợp lệ

Sau khi xây dựng được mô hình phân loại cảm xúc từ nội dung đánh giá, hệ thống

tiến hành so sánh kết quả dự đoán với điểm số (rating) gốc do người dùng cung cấp. Dựa trên giả định rằng nội dung và điểm số phải nhất quán về mặt cảm xúc, một đánh giá được xem là **không hợp lệ** nếu thỏa mãn điều kiện:

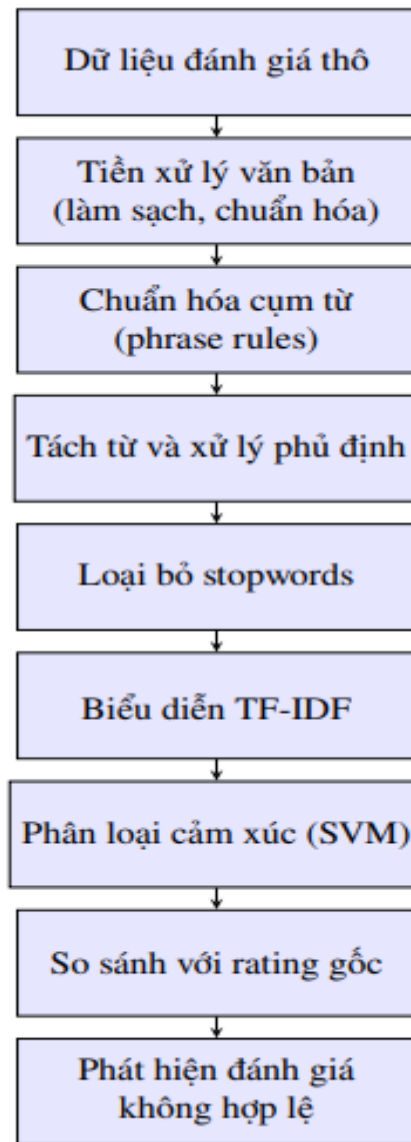
- **Nội dung mang cảm xúc tích cực nhưng rating thấp (1 hoặc 2).**
- **Nội dung mang cảm xúc tiêu cực nhưng rating cao (4 hoặc 5).**

Các đánh giá không hợp lệ có thể đến từ:

- Lỗi hệ thống hoặc thao tác sai của người dùng khi chọn rating.
- Hành vi bất thường như spam, đánh giá giả mạo, hoặc cảm xúc thay đổi trong nội dung.
- Người dùng sử dụng ngôn ngữ mỉa mai, gián tiếp (được xử lý hạn chế trong bước phân tích ngữ nghĩa).

Việc phát hiện các đánh giá không hợp lệ đóng vai trò quan trọng trong việc **lọc nhiễu đầu vào** cho hệ thống đề xuất, từ đó cải thiện độ chính xác và tin cậy của các gợi ý sản phẩm.

3.2.5. *Tổng quan pipeline xử lý*



Hình 3.1: Pipeline xử lý văn bản và phát hiện đánh giá không hợp lệ

Pipeline xử lý này là xương sống cho toàn bộ hệ thống, kết nối trực tiếp giữa dữ liệu thô và các mô-đun phân tích nâng cao được trình bày trong các chương sau.

3.3. Mô tả kiến trúc hệ thống: sơ đồ tổng quát các khối chức năng

3.3.1. Tổng quan hệ thống

Hệ thống được triển khai nhằm thực hiện nhiệm vụ phân tích đánh giá người dùng, phát hiện các đánh giá không hợp lệ, và cải thiện chất lượng gợi ý sản phẩm. Kiến trúc tổng thể gồm nhiều thành phần hoạt động độc lập nhưng liên kết chặt chẽ thông qua API. Các khối chức năng chính bao gồm:

- **Frontend (Next.js):** là giao diện người dùng nơi người dùng nhập đánh giá, tương tác với hệ thống và nhận kết quả gợi ý. Giao diện gửi dữ liệu đến backend và hiển thị phản hồi từ hệ thống.

- **Backend (Node.js):** xử lý các yêu cầu từ frontend, định tuyến dữ liệu, gọi các mô-đun xử lý cảm xúc và mô hình gợi ý. Backend đóng vai trò trung tâm điều phối.

- **Sentiment Analysis Model (SVM):** mô hình học máy được huấn luyện để phân loại cảm xúc từ văn bản đánh giá. Mô hình này nhận dữ liệu từ backend, dự đoán nhãn cảm xúc, và trả kết quả lại.

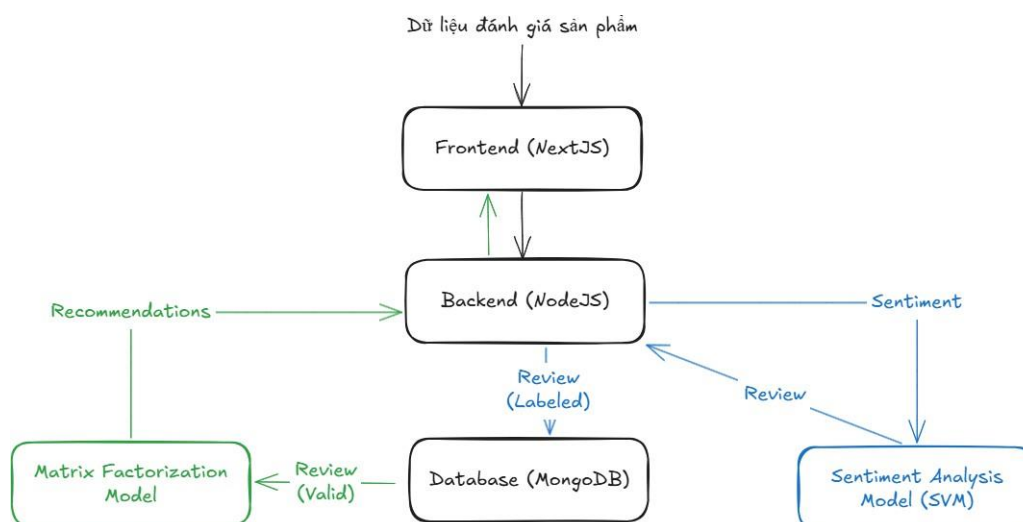
- **Database (MongoDB):** cơ sở dữ liệu lưu trữ toàn bộ đánh giá, thông tin sản phẩm, kết quả phân tích cảm xúc và kết quả lọc.

- **Matrix Factorization Model:** mô hình gợi ý sản phẩm, sử dụng dữ liệu đã lọc để xây dựng ma trận người dùng–sản phẩm. Mô hình này đầu ra là danh sách sản phẩm được cá nhân hóa cho từng người dùng.

3.3.2. *Luồng dữ liệu và tương tác*

Hình 3.2 mô tả trực quan luồng dữ liệu giữa các thành phần trong hệ thống. Cụ thể:

1. Người dùng nhập đánh giá sản phẩm thông qua frontend.
2. Dữ liệu được chuyển đến backend để xử lý.
3. Backend lưu dữ liệu xuống cơ sở dữ liệu MongoDB.
4. Đồng thời, đánh giá được gửi đến mô hình phân tích cảm xúc (SVM) để xác định nhãn cảm xúc.
5. Kết quả phân tích cảm xúc được trả về backend và lưu cùng dữ liệu gốc.
6. Backend sử dụng dữ liệu đã được dán nhãn cảm xúc để phát hiện các đánh giá không hợp lệ.
7. Những đánh giá hợp lệ sẽ được đưa vào mô hình gợi ý (Matrix Factorization) để huấn luyện hoặc cập nhật dự đoán.
8. Cuối cùng, kết quả gợi ý được gửi về frontend để hiển thị cho người dùng.



Hình 3.2: Sơ đồ kiến trúc hệ thống lọc đánh giá người dùng và gợi ý sản phẩm

3.3.3. Khả năng mở rộng và tích hợp

Kiến trúc hiện tại được thiết kế theo nguyên tắc module hoá, cho phép dễ dàng mở rộng trong tương lai:

- Thay thế mô hình SVM bằng các mô hình học sâu như BERT hoặc LSTM để nâng cao độ chính xác.
- Tích hợp các công nghệ mới như Redis cache hoặc GraphQL để tối ưu hiệu năng truy vấn.
- Kết nối với các nguồn dữ liệu khác (ví dụ: đánh giá từ mạng xã hội hoặc diễn đàn) để tăng độ bao phủ dữ liệu.

Hệ thống mang tính linh hoạt cao và có thể áp dụng vào nhiều lĩnh vực thương mại điện tử khác nhau với cấu trúc tương tự.

3.4. Các yếu tố thiết kế quan trọng

Quá trình thiết kế và triển khai hệ thống không chỉ dừng lại ở các thành phần chức năng, mà còn đòi hỏi sự chú trọng đến các yếu tố kỹ thuật cốt lõi ảnh hưởng trực tiếp đến độ tin cậy, khả năng mở rộng và hiệu quả xử lý. Ba yếu tố chính bao gồm: dữ liệu đầu vào/đầu ra, mô-đun huấn luyện và cơ chế lưu trữ kết quả.

3.4.1. Dữ liệu đầu vào và đầu ra

- **Dữ liệu đầu vào:** Hệ thống tiếp nhận hai loại dữ liệu đầu vào chính:

- Dữ liệu đánh giá từ người dùng (bình luận văn bản và điểm số).
- Dữ liệu sản phẩm từ sàn thương mại điện tử (tên sách, danh mục, mô tả).

Dữ liệu được xử lý tiền xử lý trước khi đưa vào pipeline học máy, nhằm loại bỏ

nhiều, chuẩn hóa ngữ nghĩa và đảm bảo tính đồng nhất.

- **Dữ liệu đầu ra:** Tùy theo giai đoạn xử lý, hệ thống tạo ra ba loại kết quả:
 - Nhãn cảm xúc (tích cực hoặc tiêu cực) gán cho mỗi đánh giá.
 - Cảnh báo đánh giá không hợp lệ nếu có sự mâu thuẫn giữa nội dung và điểm số.
 - Danh sách gợi ý sản phẩm cá nhân hóa cho từng người dùng.

3.4.2. Mô-đun huấn luyện và dự đoán

Hệ thống bao gồm hai mô-đun học máy độc lập, mỗi mô-đun đảm nhận vai trò cụ thể trong pipeline xử lý:

- **Mô hình phân tích cảm xúc (SVM):** sử dụng dữ liệu đánh giá văn bản đã được gán nhãn (dựa vào rating) để huấn luyện mô hình phân loại nhị phân. Mô hình SVM được lựa chọn nhờ khả năng phân biệt rõ ràng trong không gian đặc trưng thưa (TF-IDF) và tốc độ huấn luyện nhanh.

- **Mô hình đề xuất (Matrix Factorization):** sử dụng tập người dùng – sản phẩm với điểm số đã được lọc hoặc điều chỉnh để xây dựng ma trận dự đoán ẩn. Việc huấn luyện mô hình được thực hiện theo chiến lược offline, với khả năng cập nhật định kỳ hoặc theo chu kỳ học online trong tương lai.

Các mô hình được đóng gói thành module độc lập (bằng Python hoặc thư viện Scikit-learn), có thể dễ dàng tích hợp vào backend thông qua API hoặc script xử lý nền.

3.4.3. Cơ chế lưu trữ và quản lý kết quả

Hệ thống sử dụng cơ sở dữ liệu **MongoDB** để lưu trữ tất cả thông tin liên quan, bao gồm:

- Dữ liệu thô: thông tin sản phẩm, đánh giá gốc của người dùng.
- Dữ liệu đã xử lý: văn bản đã chuẩn hóa, kết quả phân tích cảm xúc, nhãn phân loại.
- Kết quả mô hình: ma trận người dùng–sản phẩm, danh sách sản phẩm gợi ý, chỉ số đánh giá mô hình (MAE, RMSE).

Cơ sở dữ liệu được thiết kế theo hướng phi quan hệ (NoSQL), linh hoạt trong việc mở rộng schema, cho phép lưu trữ cả văn bản, mảng số liệu và các đối tượng kết quả trung gian.

Các bản ghi có thể được truy vấn trực tiếp từ backend để phục vụ hiển thị trên giao diện người dùng hoặc làm đầu vào cho các mô hình tiếp theo. Ngoài ra, hệ thống có khả năng xuất kết quả ra định dạng CSV hoặc JSON để phục vụ trực quan hóa và phân

tích bên ngoài.

3.4.4. Tính mở rộng và bảo trì

Toàn bộ hệ thống được tổ chức theo kiến trúc module, mỗi thành phần có thể dễ dàng bảo trì, cập nhật hoặc thay thế độc lập. Một số định hướng nâng cấp trong tương lai gồm:

- Tích hợp mô hình học sâu (Deep Learning) cho phân tích cảm xúc nâng cao.
- Áp dụng học liên tục (online learning) cho hệ thống đề xuất theo thời gian thực.
- Tự động gán nhãn cảm xúc bằng mô hình pre-trained thay vì dựa vào rating.
- Lưu trữ dữ liệu trên hệ thống phân tán như MongoDB Cluster hoặc ElasticSearch.

Nhờ tính linh hoạt này, hệ thống có khả năng thích ứng với khối lượng dữ liệu lớn hơn cũng như các bài toán tương tự trong các miền ứng dụng khác.

CHƯƠNG 4: THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

Chương này trình bày quá trình thực nghiệm đánh giá hiệu quả của hệ thống đề xuất và mô hình phân tích cảm xúc. Các kết quả được so sánh và phân tích nhằm rút ra vai trò của bước lọc đánh giá trong việc nâng cao chất lượng đề xuất sản phẩm.

4.1. Thực nghiệm mô hình phân tích cảm xúc

4.1.1. Tập dữ liệu và tiền xử lý

Để huấn luyện mô hình phân loại cảm xúc, tôi xây dựng một tập dữ liệu gồm **4.024** đánh giá văn bản tiếng Việt từ người dùng trên nền tảng thương mại điện tử Tiki.vn. Mỗi đánh giá bao gồm hai thông tin chính: nội dung bình luận và điểm số (rating) từ 1 đến 5. Tuy nhiên, thay vì sử dụng trực tiếp điểm số làm nhãn cảm xúc, tôi áp dụng phương pháp gán nhãn bán tự động kết hợp giữa mô hình ngôn ngữ lớn (ChatGPT) và kiểm tra thủ công nhằm đảm bảo độ tin cậy cho tập huấn luyện.

Quy trình gán nhãn cảm xúc

1. **Gán nhãn sơ bộ bằng ChatGPT:** Từng đánh giá được đưa vào mô hình ChatGPT để phân loại cảm xúc thành hai nhãn: pos (tích cực) hoặc neg (tiêu cực). Việc gán nhãn dựa trên nội dung ngữ nghĩa của đánh giá, không phụ thuộc vào điểm số gốc. Ví dụ:

“Hãy đọc đoạn đánh giá sau và phân loại cảm xúc người viết là tích cực (pos) hoặc tiêu cực (neg). Trả lời duy nhất bằng pos hoặc neg.”

2. **Hiệu chỉnh thủ công:** Sau khi ChatGPT gán nhãn cho toàn bộ tập dữ liệu, tôi tiến hành rà soát thủ công lại toàn bộ các mẫu đã được dán nhãn. Những trường hợp có cảm xúc mơ hồ, giọng điệu mỉa mai, hoặc mâu thuẫn với rating được điều chỉnh lại để đảm bảo tính nhất quán và chất lượng dữ liệu đầu vào.

Việc kết hợp gán nhãn tự động và kiểm tra thủ công giúp tiết kiệm đáng kể thời gian nhưng vẫn duy trì được độ chính xác của bộ dữ liệu.

Phân bố nhãn cảm xúc cuối cùng

Sau quá trình hiệu chỉnh, dữ liệu được phân thành hai lớp cảm xúc như sau:

Bảng 4.1: Phân bố nhãn cảm xúc trong tập dữ liệu huấn luyện

Nhãn cảm xúc	Số lượng đánh giá
Tích cực (pos)	1.911
Tiêu cực (neg)	2.113
Tổng cộng	4.024

Tiền xử lý văn bản

Trước khi đưa vào mô hình học máy, dữ liệu văn bản được chuẩn hóa thông qua pipeline tiền xử lý bao gồm:

1. **Làm sạch văn bản:** Loại bỏ emoji, ký tự đặc biệt, liên kết URL và định dạng lỗi (ví dụ:

`_x000D_`).

2. **Chuẩn hóa ngôn ngữ:** Thay thế các từ viết tắt (teencode), từ tiếng Anh phổ biến bằng tương đương tiếng Việt.

3. **Tách từ và xử lý cấu trúc ngữ nghĩa:** Áp dụng công cụ VnTokenizer để tách từ, chuẩn hóa phủ định và cụm từ cố định.

4. **Xoá từ dừng (stopwords):** Loại bỏ các từ không mang ngữ nghĩa phân loại như “là”, “có”, “một”, “và”, ...

5. **Trích xuất đặc trưng:** Sử dụng mô hình TF-IDF Vectorizer để biểu diễn văn bản thành dạng vector số phục vụ cho mô hình học máy.

Nhờ quy trình tiền xử lý kỹ lưỡng, tập dữ liệu đầu vào đạt chất lượng cao, phục vụ hiệu quả cho việc huấn luyện mô hình phân loại cảm xúc được trình bày trong phần tiếp theo.

Các bước tiền xử lý

Vì dữ liệu đánh giá mang tính tự nhiên, đa dạng ngôn ngữ và biểu cảm, việc tiền xử lý là bước thiết yếu nhằm chuẩn hóa và làm sạch đầu vào. Các bước thực hiện cụ thể như sau:

1. **Làm sạch văn bản:** loại bỏ các ký tự đặc biệt, biểu tượng cảm xúc (emoji), đoạn văn lỗi định dạng như “`_x000D_`”, đường dẫn URL và chuyển toàn bộ văn bản sang chữ thường.

2. **Chuẩn hóa teencode và từ viết tắt:** sử dụng từ điển ánh xạ để thay thế các từ như “tks”

→ “cảm ơn”, “hok” → “không”.

3. **Ghép cụm từ quan trọng (phrase rules):** nối các cụm từ như “giao hàng” → “giao_hàng” để giữ nguyên ngữ nghĩa trong quá trình tách từ.

4. **Xử lý phủ định và cụm tiêu cực:** nối cụm từ phủ định như “không tốt” → “không_tốt” hoặc “bị móp” → “bị_móp” nhằm bảo tồn cảm xúc.

5. **Tách từ tiếng Việt:** sử dụng thư viện `pyvi.ViTokenizer` để tách các câu thành danh sách từ đơn vị.

6. **Xoá từ dừng:** áp dụng danh sách stopwords tiếng Việt để loại bỏ các từ không có tính phân biệt về mặt cảm xúc như “là”, “nhưng”, “đã”.

7. **Biểu diễn đặc trưng:** sử dụng **TF-IDF Vectorizer** với cấu hình:

- `max_features = 3000`
- `min_df = 5, max_df = 0.8`
- `sublinear_tf = True`
- N-gram: (1, 2)(unigram + bigram)

Kết quả, mỗi đánh giá văn bản được biểu diễn thành một vector thưa (sparse vector) phản ánh mức độ nổi bật của các cụm từ quan trọng trong ngữ cảnh cảm xúc.

4.1.2. Huấn luyện mô hình và đánh giá

Mô hình được sử dụng là **SVM (Support Vector Machine)** với kernel tuyến tính, huấn luyện bằng thư viện `scikit-learn`. Dữ liệu được chia thành hai phần:

- **Tập huấn luyện:** 80% dữ liệu
- **Tập kiểm tra:** 20% còn lại, dùng để đánh giá độ chính xác và tính tổng quát hóa

Sau khi huấn luyện, mô hình được đánh giá dựa trên các chỉ số:

- **Độ chính xác (Accuracy)**
- **Precision, Recall, F1-score cho từng lớp**
- **Ma trận nhầm lẫn (Confusion Matrix)**

Kết quả đánh giá mô hình SVM


Bảng 4.2: Ma trận nhầm lẫn mô hình SVM

	Dự đoán: pos	Dự đoán: neg
Thực tế: pos	528	64
Thực tế: neg	42	567

Các chỉ số tổng hợp:

- **Accuracy:** 91.17%
- **F1-score (pos):** 0.91 **F1-score (neg):** 0.91
- **Precision (pos/neg):** 0.93 / 0.90
- **Recall (pos/neg):** 0.89 / 0.93

4.1.3. Phân tích kết quả



Hình 4.1: Biểu đồ Confusion Matrix của mô hình SVM

Mô hình SVM thể hiện hiệu suất phân loại tốt và ổn định. F1-score của hai lớp gần như tương đương (đều đạt 0.91), cho thấy sự cân bằng giữa hai nhãn cảm xúc. Cụ thể:

- Chỉ có 64 đánh giá tích cực bị phân loại sai sang tiêu cực (FN).
- 42 đánh giá tiêu cực bị nhầm thành tích cực (FP).

Tổng số lỗi phân loại chiếm tỷ lệ nhỏ trong toàn bộ tập kiểm thử, chứng tỏ mô hình đã học tốt đặc trưng cảm xúc từ văn bản.

4.1.4. Minh họa kết quả dự đoán

Một số ví dụ thực tế từ tập kiểm tra được minh họa trong Bảng 4.3:

Bảng 4.3: Một số mẫu đầu vào và nhãn dự đoán cảm xúc

Rating	Bình luận	Label (dự đoán)
5	Một quyển sách hay	pos
5	Sách đẹp, hài lòng	pos

5	Ok sách đẹp	pos
2	Giao hàng tệ, sách rách	neg
1	Mất thời gian, không đáng đọc	neg

4.1.5. Kết luận phân thực nghiệm cảm xúc

Thực nghiệm đã chứng minh rằng mô hình SVM có khả năng phân loại cảm xúc đánh giá người dùng tiếng Việt với độ chính xác trên 91%. Mô hình đạt hiệu suất cao, F1-score đồng đều cho cả hai lớp, và đặc biệt hiệu quả với dữ liệu văn bản sau khi tiền xử lý kỹ lưỡng. Đây là cơ sở đáng tin cậy để tích hợp vào hệ thống phát hiện đánh giá không hợp lệ và cải thiện chất lượng đề xuất sản phẩm.

4.2. Thực nghiệm hệ thống đề xuất

4.2.1. Thiết lập thực nghiệm

Trong phần này, chúng tôi tiến hành đánh giá hiệu quả của hệ thống đề xuất khi áp dụng các phương pháp xử lý đánh giá người dùng. Cụ thể, mô hình đề xuất sử dụng là **Matrix Factorization (MF)** được tối ưu bằng **thuật toán Gradient Descent**, được hiện thực trong class MFRecommender tự xây dựng.

- **Ngôn ngữ:** Python 3.10
- **Thư viện:** pandas, numpy, matplotlib
- **Tập dữ liệu:** 73.271 đánh giá thực từ người dùng trên Tiki.vn
- **Tập huấn luyện / kiểm thử:** chia theo tỉ lệ 80% / 20%
- **Số yếu tố tiềm ẩn (latent factors):** 20
- **Số epoch huấn luyện:** 20

4.2.2. Các kịch bản thực nghiệm

Ba kịch bản được xây dựng để kiểm tra hiệu quả của bước xử lý đánh giá:

- **K1 – Dữ liệu gốc:** giữ nguyên toàn bộ đánh giá ban đầu, không loại bỏ hay điều chỉnh.
- **K2 – Loại đánh giá không hợp lệ:** loại bỏ các đánh giá có mâu thuẫn giữa cảm xúc và điểm số.
- **K3 – Điều chỉnh điểm đánh giá:** thay vì loại bỏ, điều chỉnh lại điểm số theo cảm xúc và độ tin cậy của nhận xét.


4.2.3. Kết quả thực nghiệm

Sau khi huấn luyện mô hình MF trên từng kịch bản, chúng tôi đánh giá hiệu suất

dựa trên chỉ số **RMSE (Root Mean Squared Error)**.

Bảng 4.4: So sánh RMSE giữa các kịch bản

Kịch bản	RMSE (↓)
K1 – Dữ liệu gốc	0.6448
K2 – Lọc đánh giá không hợp lệ	0.6804
K3 – Điều chỉnh điểm số theo cảm xúc	0.6594



Hình 4.2: Biểu đồ so sánh RMSE giữa các kịch bản

4.2.4. Phân tích và nhận xét

- **Kịch bản 1 (K1)** cho kết quả tốt nhất về RMSE nhưng không đảm bảo độ tin cậy dữ liệu, do tồn tại nhiều đánh giá không phản ánh đúng cảm xúc thực sự của người dùng.
- **Kịch bản 2 (K2)** có RMSE cao nhất do dữ liệu bị loại bỏ khá nhiều, dẫn đến tập huấn luyện suy giảm, mô hình học chưa đủ đại diện.
- **Kịch bản 3 (K3)** đạt mức RMSE gần sát với K1, nhưng giữ lại toàn bộ dữ liệu nhờ điều chỉnh mềm điểm số, chứng minh hiệu quả của chiến lược kết hợp phân tích cảm xúc và điều chỉnh đánh giá.

4.2.5. Kết luận phần thực nghiệm đề xuất

Kết quả cho thấy, việc xử lý dữ liệu đánh giá đầu vào có ảnh hưởng rõ rệt đến hiệu suất hệ thống đề xuất. Phương pháp điều chỉnh đánh giá (K3) được xem là lựa chọn tối ưu khi vừa đảm bảo độ chính xác cao, vừa bảo toàn số lượng dữ liệu. Từ đó, ta có thể khẳng định rằng việc tích hợp phân tích cảm xúc vào hệ thống lọc đánh giá góp phần nâng cao chất lượng gợi ý.

4.3. Giao diện website demo

Để minh họa tính ứng dụng thực tế của hệ thống lọc đánh giá người dùng và mô

hình đề xuất sản phẩm, tôi đã xây dựng một **giao diện web demo** nhằm thử nghiệm luồng hoạt động từ phía người dùng đến hệ thống backend. Hệ thống sử dụng các công nghệ như Next.js cho frontend, Node.js cho backend và MongoDB cho lưu trữ dữ liệu.

4.3.1. Trang chủ và tìm kiếm sản phẩm

Giao diện chính cung cấp chức năng tìm kiếm sản phẩm sách, hiển thị thông tin cơ bản như tên, ảnh bìa và điểm đánh giá trung bình. Người dùng có thể chọn sản phẩm để xem chi tiết hoặc gửi đánh giá mới.



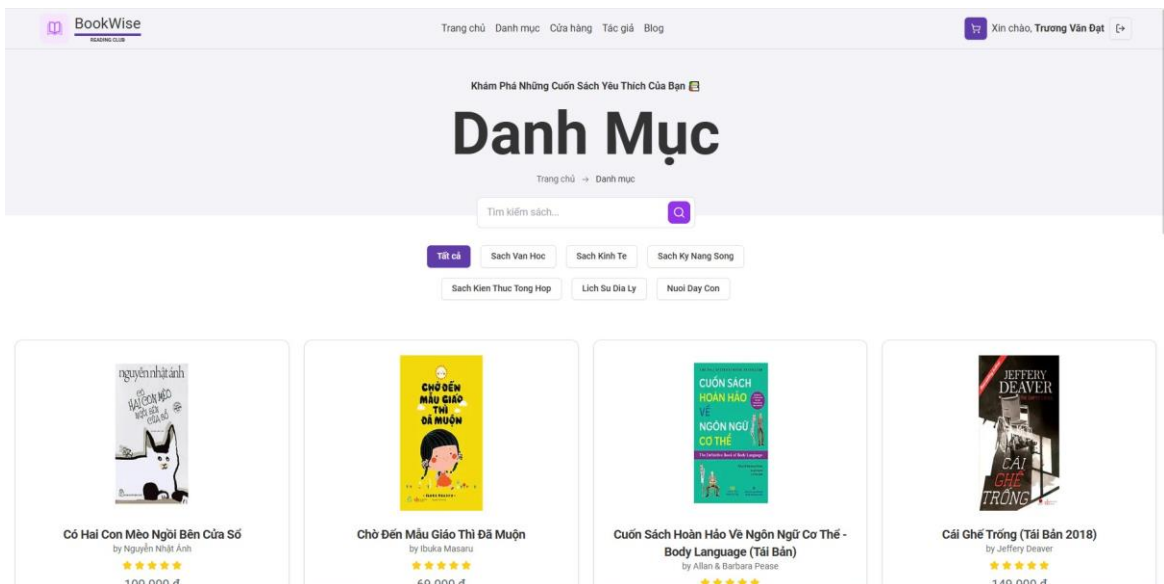
Hình 4.3: Giao diện trang chủ và tìm kiếm sách

4.3.2. Trang danh mục sản phẩm

Trang danh mục cho phép người dùng duyệt qua các nhóm sách được phân loại theo chủ đề như: Văn học, Kinh tế, Kỹ năng sống, Nuôi dạy con, Lịch sử – Địa lý, Kiến thức tổng hợp, v.v. Giao diện trực quan hỗ trợ tìm kiếm và lọc nhanh theo loại sách.

- **Thanh tìm kiếm:** cho phép nhập từ khoá để lọc danh sách theo tiêu đề sách.
- **Bộ lọc theo danh mục:** mỗi nút lọc đại diện cho một thể loại sách, cho phép hiển thị các sản phẩm thuộc loại tương ứng.
- **Danh sách sản phẩm:** hiển thị hình ảnh bìa sách, tiêu đề, tác giả, giá và điểm đánh giá trung bình dưới dạng sao.

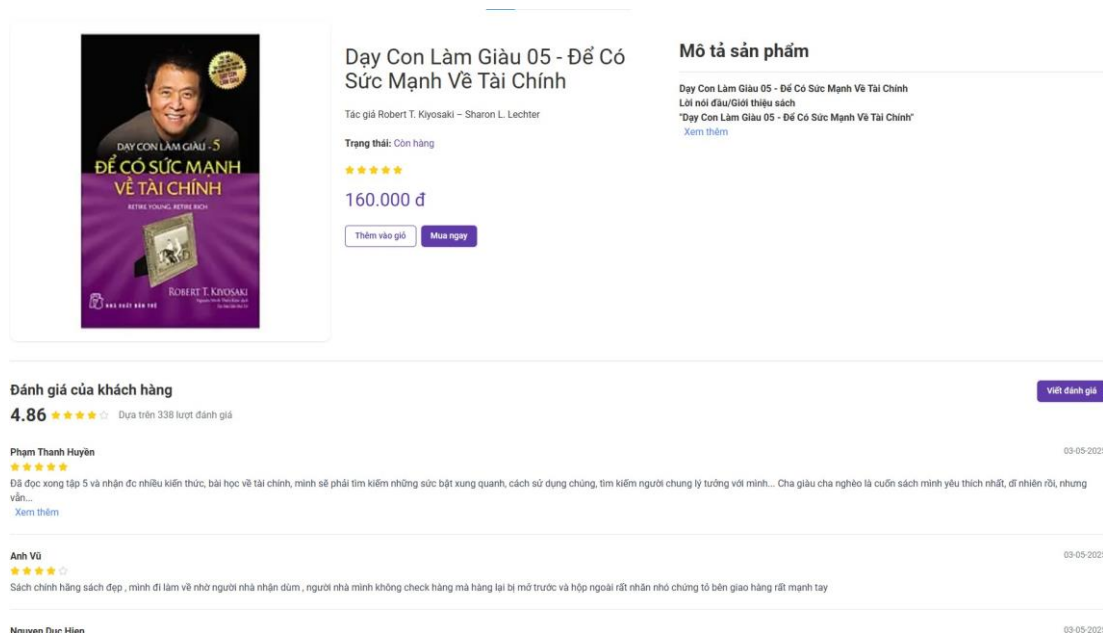
Giao diện này đóng vai trò là điểm khởi đầu chính để người dùng tiếp cận kho sách, từ đó có thể chọn sản phẩm yêu thích và thực hiện đánh giá.



Hình 4.4: Giao diện trang danh mục sản phẩm với chức năng tìm kiếm và lọc theo thể loại

4.3.3. Trang chi tiết sản phẩm và đánh giá người dùng

Người dùng có thể truy cập vào chi tiết một sản phẩm cụ thể để xem toàn bộ các đánh giá từ người dùng khác. Đồng thời, hệ thống cung cấp biểu mẫu để người dùng nhập bình luận mới và chấm điểm sản phẩm.




Hình 4.5: Trang chi tiết sản phẩm và các đánh giá liên quan

4.3.4. Trang gợi ý sản phẩm cá nhân hóa

Cuối cùng, người dùng có thể truy cập mục “Sản phẩm dành cho bạn” để nhận các gợi ý từ hệ thống dựa trên hành vi đánh giá cá nhân. Mô hình Matrix Factorization sử dụng các đánh giá đã lọc để tạo ra các gợi ý chính xác hơn.

Những đề xuất dành cho bạn

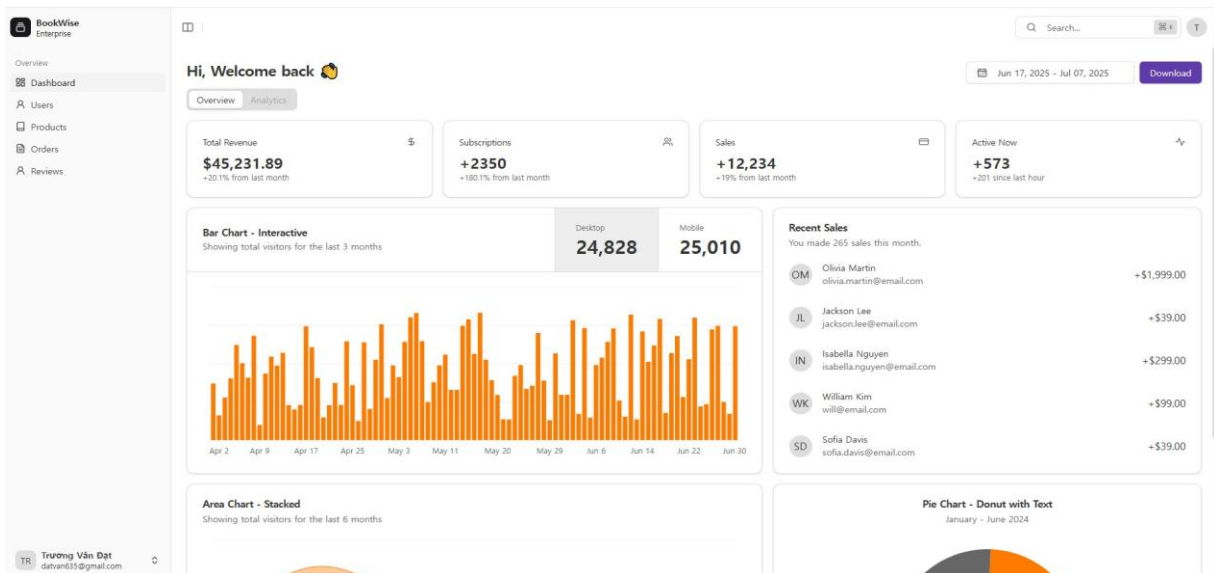


Hình 4.6: Giao diện gợi ý sách theo cá nhân hóa người dùng

4.3.5. Trang quản trị và thống kê hệ thống

Ngoài các chức năng dành cho người dùng cuối, hệ thống còn cung cấp một giao diện quản trị (admin dashboard) cho phép người quản trị theo dõi và kiểm soát dữ liệu hệ thống, bao gồm thông tin đánh giá, hoạt động người dùng và hiệu quả gợi ý. Giao diện này được xây dựng bằng framework Next.js, tích hợp biểu đồ và bảng thống kê tương tác.

- **Tổng quan hoạt động:** thống kê số lượng doanh thu, lượt đánh giá, người dùng đang hoạt động và tần suất truy cập gần đây.
- **Biểu đồ tương tác:** trực quan hoá dữ liệu bằng biểu đồ cột (bar chart), biểu đồ vùng (area chart), biểu đồ tròn (pie chart), phục vụ theo dõi xu hướng sử dụng.
- **Lịch sử đánh giá:** hiển thị danh sách các đánh giá mới nhất cùng địa chỉ email người đánh giá.
- **Tính năng lọc và xuất dữ liệu:** người quản trị có thể chọn khoảng thời gian để lọc thống kê và xuất báo cáo.



Hình 4.7: Giao diện trang quản trị hệ thống với biểu đồ và bảng thống kê

Trang quản trị đóng vai trò hỗ trợ người vận hành kiểm tra dữ liệu đầu vào, giám sát các lượt tương tác, và theo dõi hiệu quả của hệ thống lọc đánh giá và đề xuất. Trong tương lai, trang này có thể được mở rộng thêm để quản lý người dùng, phân tích mức độ tin cậy của đánh giá, hoặc trực tiếp hiệu chỉnh dữ liệu bất thường.

4.3.6. Phân tích đánh giá và lọc nội dung bất thường

Sau khi người dùng gửi đánh giá, hệ thống thực hiện phân tích cảm xúc tự động. Nếu phát hiện mâu thuẫn giữa nội dung và điểm số, đánh giá sẽ được đánh dấu là “không hợp lệ” và có thể bị loại bỏ hoặc điều chỉnh lại điểm trong hệ thống gợi ý.

Review (296516)
Manage reviews

Search name... Validity: [dropdown] Sentiment: [dropdown]

<input type="checkbox"/>	User ID	Product ID	Rating	Comment	Sentiment	Is Valid
<input type="checkbox"/>	6815a36e023f6e392171524	6815c02c82917a0d9a9aaa5c	5	Tác phẩm có giá trị về truyền thống hơn là giá trị về lịch sử. Sách in đẹp, mỗi trang đều kèm theo hình minh họa. Thích hai câu đầu và hai câu cuối của tác phẩm.	pos	Yes
<input type="checkbox"/>	6815af36023f6e392191150	6815c02c82917a0d9a9aaa5c	5			Yes
<input type="checkbox"/>	6815a4506023f6e392173825	6815c02c82917a0d9a9aaa5c	4			Yes
<input type="checkbox"/>	6815aa96023f6e392184603	6815c02c82917a0d9a9aaa5c	5	Tác phẩm theo mình đánh giá là một trong những tác phẩm hay nhất của Bác, giúp ta hiểu hơn về lịch sử dân tộc.	pos	Yes
<input type="checkbox"/>	6815b2556023f6e392196bec	6815c02c82917a0d9a9aaa5c	5			Yes
<input type="checkbox"/>	6815ae58023f6e39218d37a	6815c02c82917a0d9a9aaa5c	5			Yes
<input type="checkbox"/>	6815a9366023f6e3921803a4	6815c02c82917a0d9a9aaa5c	4	OK	pos	Yes
<input type="checkbox"/>	6815aa1d6023f6e392182283	6815c02c82917a0d9a9aaa5c	5			Yes
<input type="checkbox"/>	6815ac3a023f6e3921882c5	6815c02c82917a0d9a9aaa5c	5			Yes
<input type="checkbox"/>	6815a9366023f6e392180392	6815c02c82917a0d9a9aaa5c	4	Tốt	pos	Yes

Showing 1 to 10 of 296516 entries Rows per page: 10 Page 1 of 29652

Hình 4.8: Giao diện hiển thị kết quả phân tích cảm xúc và cảnh báo đánh giá không hợp lệ

4.3.7. Tổng kết phần giao diện

Giao diện web được xây dựng để minh họa trực quan quá trình vận hành của hệ thống, từ việc tiếp nhận dữ liệu người dùng, xử lý cảm xúc cho đến gợi ý sản phẩm. Hệ thống có thể dễ dàng mở rộng để tích hợp vào các nền tảng thương mại điện tử thực tế.

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết luận

Trong khuôn khổ đề án này, tôi đã xây dựng và triển khai một hệ thống nhằm **lọc các đánh giá không hợp lệ của người dùng** với mục tiêu cải thiện chất lượng của hệ thống đề xuất sản phẩm. Toàn bộ quy trình được thực hiện qua các bước chính như: thu thập và xử lý dữ liệu đánh giá từ nền tảng thương mại điện tử Tiki, gán nhãn và phân loại cảm xúc bằng mô hình SVM, so sánh cảm xúc với điểm số đánh giá để phát hiện bất nhất, và cuối cùng là tích hợp kết quả lọc vào mô hình đề xuất sử dụng Matrix Factorization.

Việc thực nghiệm trên ba kịch bản gồm: (1) sử dụng dữ liệu gốc không lọc, (2) loại bỏ các đánh giá không hợp lệ và (3) điều chỉnh điểm số của các đánh giá này, đã cho thấy rõ ràng rằng việc xử lý các đánh giá không nhất quán giúp cải thiện hiệu quả của hệ thống đề xuất. Cụ thể:

- Kịch bản loại bỏ đánh giá sai lệch giúp giảm nhiễu trong dữ liệu huấn luyện, từ đó cải thiện độ chính xác dự đoán.
- Kịch bản điều chỉnh điểm số giữ được thông tin đánh giá nhưng vẫn hạn chế ảnh hưởng tiêu cực từ sự bất nhất giữa cảm xúc và điểm số.
- So với hai phương án trên, dữ liệu gốc chứa nhiều đánh giá không đồng nhất khiến chất lượng đề xuất thấp hơn đáng kể.

Từ đó, có thể kết luận rằng mô hình lọc đánh giá người dùng không chỉ nâng cao chất lượng khuyến nghị mà còn đóng vai trò quan trọng trong việc đảm bảo độ tin cậy của dữ liệu đầu vào. Đây là đóng góp có giá trị cả về mặt học thuật lẫn ứng dụng thực tiễn, đặc biệt trong các hệ thống khuyến nghị vận hành trên dữ liệu người dùng lớn và đa dạng.

5.2. Hướng phát triển

Mặc dù đã đạt được một số kết quả tích cực, đề tài vẫn còn nhiều hướng mở rộng và cải tiến trong tương lai:

- **Ứng dụng mô hình học sâu trong phân tích cảm xúc:** Thay vì chỉ sử dụng SVM, việc áp dụng các kiến trúc mạng nơ-ron như BiLSTM, BERT hoặc PhoBERT có thể nâng cao độ chính xác phân loại cảm xúc, đặc biệt trong ngôn ngữ tiếng Việt giàu ngữ cảnh.
- **Kết hợp thông tin nội dung sản phẩm:** Việc khai thác thêm các đặc trưng nội dung của sản phẩm như thể loại, mô tả, từ khóa sẽ giúp cải thiện chất lượng đề xuất, đặc biệt đối với người dùng mới (cold-start).

- **Tích hợp các phương pháp embedding hoặc attention-based:** Việc sử dụng các kỹ thuật embedding hiện đại (như word2vec, fastText) hoặc mô hình dựa trên attention (VD: Transformer, SASRec) có thể giúp xây dựng hệ thống đề xuất dựa trên ngữ nghĩa sâu hơn, phù hợp với xu hướng hiện tại trong lĩnh vực Recommender Systems.

- **Triển khai và đánh giá trên dữ liệu lớn hơn:** Để kiểm định khả năng tổng quát, hệ thống cần được thử nghiệm trên các tập dữ liệu quy mô lớn hơn và thuộc nhiều miền sản phẩm khác nhau, ví dụ như điện tử, thời trang, thực phẩm,...

Tóm lại, đề tài đã đưa ra một phương pháp tiếp cận khả thi để lọc đánh giá người dùng và chứng minh được tác động tích cực của nó trong hệ thống đề xuất. Với các cải tiến kể trên, hệ thống có tiềm năng phát triển thành một giải pháp mạnh mẽ và linh hoạt trong thực tiễn.

TÀI LIỆU THAM KHẢO

- [1] Y. Koren và R. Bell, “Advances in collaborative filtering,” trong *Recommender Systems Handbook*, ấn bản lần 3, F. Ricci, L. Rokach và B. Shapira (biên tập), Springer, 2022, trang 91–142.
- [2] J. Zhang, Y. Guo và Y. Chen, “Trust-aware collaborative filtering for fake review detection,” *IEEE Transactions on Knowledge and Data Engineering*, tập 32, số 12, trang 2481–2494, 2020.
- [3] Z. Yang, K. Zhang và M. Sun, “Sentiment classification using deep learning approaches: A survey,” *IEEE Transactions on Affective Computing*, tập 10, số 3, trang 328–350, 2019.
- [4] B. Liu, *Sentiment Analysis: Mining Opinions, Sentiments, and Emotions*, ấn bản lần 2, Cambridge University Press, 2020.
- [5] Z. Fan, X. Liu và Q. Yang, “Enhancing recommender systems with opinion-aware review filtering,” trong *Proceedings of the Web Conference (WWW)*, 2021, trang 1129–1140.